

# Методы оптимизации

---



## Лекция 2

3 марта 2021 г.

# МЕТОДЫ ОДНОМЕРНОЙ МИНИМИЗАЦИИ С ИСПОЛЬЗОВАНИЕМ ПРОИЗВОДНОЙ

---

# Общая идея методов




Метод средней точки направлен на повышение эффективности метода деления отрезка пополам при использовании технологии исключения отрезков за счёт замены вычислений функции в трёх точках на операцию вычисления производной в средней точке  $\tilde{x} = (a + b)/2$ .

Если  $f'(\tilde{x}) > 0$ , то точка  $\tilde{x}$  лежит на участке монотонного возрастания  $f(x)$ , поэтому  $x^* < \tilde{x}$  и точку минимума следует искать на отрезке  $[a, \tilde{x}]$ .

Если  $f'(\tilde{x}) < 0$ , то точка  $\tilde{x}$  лежит на участке монотонного убывания  $f(x)$ , поэтому  $x^* > \tilde{x}$  и точку минимума следует искать на отрезке  $[\tilde{x}, b]$ .

Равенство  $f'(\tilde{x}) = 0$  означает, что точка минимума найдена точно и  $x^* = \tilde{x}$ .

# Метод средней точки



Такое исключение отрезков требует на каждой итерации только одного вычисления  $f'(\tilde{x})$  и уменьшает отрезок поиска точки минимума ровно в два раза.

Поиск заканчивается, если абсолютная величина производной меньше заданной погрешности.

# Метод средней точки

Алгоритм.

1. Задаётся начальный интервал неопределённости  $L_0 := [a_0, b_0]$  и  $\varepsilon > 0$  — требуемая точность.
2. Задать  $k = 0$ .
3. Вычислить среднюю точку  $\tilde{x} := \frac{a_k + b_k}{2}$ ,  $f'(\tilde{x})$ .
4. Проверить условие окончания:
  - если  $|f'(\tilde{x})| \leq \varepsilon$ , то процесс поиска завершается и  $x^* := \tilde{x}$ ,  $f^* := f(x^*)$ ;
  - если  $|f'(\tilde{x})| > \varepsilon$ , то сравнить  $f'(\tilde{x})$  с нулём.  
Если  $f'(\tilde{x}) > 0$ , то продолжить поиск на отрезке  $L_k := [a_k, b_k]$ , положив  $k := k + 1$ ,  $a_k := a_{k-1}$ ,  $b_k := \tilde{x}_{k-1}$ .  
Если  $f'(\tilde{x}) \leq 0$ , то продолжить поиск на отрезке  $L_k := [a_k, b_k]$ , положив  $k := k + 1$ ,  $a_k := \tilde{x}_{k-1}$ ,  $b_k := b_{k-1}$ .  
Перейти к п. 3.

Метод хорд опирается на равенство  $f'(x) = 0$ , которое является необходимым и достаточным условием глобального минимума выпуклой дифференцируемой функции  $f(x)$ .

## Определение.

Функция  $f$ , определённая на выпуклом множестве  $X \in \mathbb{R}^n$ , называется выпуклой на  $X$ , если для произвольных элементов  $x^1, x^2 \in X$ , и для любого числа  $\lambda \in [0, 1]$  выполняется неравенство Йенсена:

$$f(\lambda x^1 + (1 - \lambda)x^2) \leq \lambda f(x^1) + (1 - \lambda)f(x^2).$$


## Определение.

Функция  $f: X \rightarrow \mathbb{R}$  называется квазивыпуклой или унимодальной, если для произвольных элементов  $x^1, x^2 \in X$  и  $\lambda \in [0, 1]$  выполняется неравенство:


$$f(\lambda x^1 + (1 - \lambda)x^2) \leq \max(f(x^1), f(x^2)).$$

# Метод хорд

Геометрически выпуклость функции  $f$  означает, что любая точка произвольной хорды графика  $f$  располагается не ниже соответствующей точки самого графика. Для вогнутой функции взаимное расположение хорды и графика обратно.



*a*




*б*

Выпуклая функция (а), вогнутая функция (б)



Произвольная выпуклая функция является квазивыпуклой (унимодальной), произвольная вогнутая функция является квазивогнутой.

Пример унимодальной функции, не являющейся выпуклой:



## Теорема Больцано-Коши.

Пусть дана непрерывная функция на отрезке  $f \in C([a, b])$ . Пусть также  $f(a) \neq f(b)$ , и без ограничения общности предположим, что  $f(a) = A < B = f(b)$ . Тогда для любого  $C \in [A, B]$  существует  $c \in [a, b]$  такое, что  $f(c) = C$ .

Если на концах отрезка  $L = [a, b]$  производная имеет разные знаки, то на интервале  $(a, b)$  найдется точка, в которой  $f'(x) = 0$  и поиск точки минимума  $f(x)$  на отрезке  $[a, b]$  эквивалентен решению уравнения



$$f'(x) = 0, \quad x \in [a, b].$$

# Метод хорд

Таким образом, любой приближённый метод решения уравнения  $f'(x) = 0$ ,  $x \in [a, b]$  можно рассматривать как метод минимизации выпуклой дифференцируемой функции  $f(x)$  на отрезке  $[a, b]$ . Одним из таких методов является метод хорд. Он основан на исключении отрезка путём определения точки

$$\tilde{x} = a - \frac{f'(a)}{f'(a) - f'(b)}(a - b)$$

пересечения с осью  $Ox$  хорды графика функции  $f'(x)$  на очередном отрезке.



Новыми точками отрезка  $[a, b]$  для осуществления следующей итерации являются концы того из отрезков  $[a, \tilde{x}]$  и  $[\tilde{x}, b]$ , который содержит точку  $x^*$ . Его определяют по знаку производной  $f'(\tilde{x})$ .

Если  $f'(\tilde{x}) > 0$ , то точка  $\tilde{x}$  лежит на участке монотонного возрастания  $f(x)$ , поэтому  $x^* < \tilde{x}$  и точку минимума следует искать на отрезке  $[a, \tilde{x}]$ , то есть  $b := \tilde{x}$ .

Если  $f'(\tilde{x}) < 0$ , то точка  $\tilde{x}$  лежит на участке монотонного убывания  $f(x)$ , поэтому  $x^* > \tilde{x}$  и точку минимума следует искать на отрезке  $[\tilde{x}, b]$ , то есть  $a := \tilde{x}$ .

Равенство  $f'(\tilde{x}) = 0$  означает, что точка минимума найдена точно и  $x^* := \tilde{x}$ .

На каждой итерации, кроме первой, следует вычислять одно новое значение  $f'(x)$ .

Поиск заканчивается, если абсолютная величина производной меньше заданной погрешности.

Алгоритм поиска минимума функции методом хорд сводится к выполнению следующих этапов.

1. Задаётся начальный интервал неопределённости  $L_0 := [a_0, b_0]$  и  $\varepsilon > 0$  — требуемая точность.

2. Задать  $k := 0$ . Вычислить  $f'(a_k), f'(b_k)$ .

Если  $f'(a_k)f'(b_k) < 0$ , то перейти к п. 3, иначе к п. 5.

3. Вычислить  $x_k := a_k - \frac{f'(a_k)}{f'(a_k) - f'(b_k)}(a_k - b_k)$  и  $f'(x_k)$ .

4. Проверить условие окончания:

- если  $|f'(x_k)| \leq \varepsilon$ , то процесс поиска завершается и  $x^* := x_k$ ,  $f^* := f(x^*)$ ;
- если  $|f'(x_k)| > \varepsilon$ , то сравнить  $f'(x_k)$  с нулём.

Если  $f'(x_k) > 0$ , то продолжить поиск на отрезке  $L_k = [a_k, b_k]$ , положив  $k := k + 1$ ,  $a_k := a_{k-1}$ ,  $b_k := x_{k-1}$ ,  $f'(b_k) := f'(x_{k-1})$ .  
Если  $f'(x_k) \leq 0$ , то продолжить поиск на отрезке  $L_k = [a_k, b_k]$ , положив  $k := k + 1$ ,  $a_k := x_{k-1}$ ,  $b_k := b_{k-1}$ ,  $f'(a_k) := f'(x_{k-1})$ .  
Перейти к п. 3.


5. Если  $f'(a_k) > 0$ ,  $f'(b_k) > 0$ , то  $f(x)$  возрастает на отрезке  $L_k = [a_k, b_k]$  и, следовательно,  $x^* := a_k$ .

Если  $f'(a_k) < 0$ ,  $f'(b_k) < 0$ , то  $f(x)$  убывает на отрезке  $L_k := [a_k, b_k]$  и, следовательно,  $x^* := b_k$ .

Если  $f'(a_k)f'(b_k) = 0$ , то  $x^* := a_k$  или  $x^* := b_k$ , в зависимости от того, на каком из концов отрезка  $L_k = [a_k, b_k]$  производная  $f'(x) = 0$ .

# Метод касательных (Ньютона-Рафсона)

Основная идея метода заключается в следующем: задаётся начальное приближение вблизи предположительного корня, после чего строится касательная к графику исследуемой функции в точке приближения, для которой находится пересечение с осью абсцисс. Эта точка берётся в качестве следующего приближения. И так далее, пока не будет достигнута необходимая точность.



# Метод касательных (Ньютона-Рафсона)

Формула итеративного приближения  $x_n$  к  $x^*$  может быть выведена из геометрического смысла касательной следующим образом:

$$f'(x_n) = \operatorname{tg} \alpha_n = \frac{\Delta y}{\Delta x} = \frac{f(x_n) - 0}{x_n - x_{n+1}} = \frac{0 - f(x_n)}{x_{n+1} - x_n},$$

где  $\alpha_n$  — угол наклона касательной прямой  $y(x) = f(x_n) + (x - x_n) \cdot \operatorname{tg} \alpha_n$  к графику  $f$  в точке  $(x_n; f(x_n))$ .

Следовательно (в уравнении касательной прямой полагаем  $y(x_{n+1}) = 0$ ) искомое выражение для  $x_{n+1}$  имеет вид:

$$x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)}.$$

Если  $x_{n+1} \in (a, b)$ , то это значение можно использовать в качестве следующего приближения к  $x^*$ .

Если  $x_{n+1} \notin (a, b)$ , то имеет место «перелёт» (корень  $x^*$  лежит рядом с границей  $(a, b)$ ). В этом случае надо (воспользовавшись идеей метода половинного деления) заменять  $x_{n+1}$  на  $\frac{x_n + x_{n+1}}{2}$  до тех пор, пока точка «не вернётся» в область поиска  $(a, b)$ .



# Метод касательных (Ньютона-Рафсона)

Алгоритм.


1. Задаётся начальный интервал неопределённости  $L_0 = [a_0, b_0]$  и  $\varepsilon > 0$  — требуемая точность.
2. Задать  $k := 0$  и начальную точку  $x_k \in [a_k, b_k]$ .
3. Вычислить  $f'(x_k)$ . Проверить условие окончания:
  - если  $|f'(x_k)| \leq \varepsilon$ , то процесс поиска завершается и  $x^* := x_k$ ,  $f^* := f(x^*)$ ;
  - если  $|f'(x_k)| > \varepsilon$ , то вычислить  $f''(x_k)$  и если  $f''(x_k) > 0$  перейти к п. 4. В противном случае закончить вычисление в связи с нарушением обязательного условия  $f''(x_k) > 0$ .
4. Вычислить  $x_{k+1} := x_k - \frac{f'(x_k)}{f''(x_k)}$ .
5. Принять  $k := k + 1$  и перейти к п. 3.

# МЕТОДЫ МИНИМИЗАЦИИ МНОГОЭКСТРЕМАЛЬНЫХ ФУНКЦИЙ

---

# Минимизация многоэкстремальных функций

Задача отыскания глобального экстремума многоэкстремальной функции существенно труднее задачи минимизации унимодальной функции.



# Постановка задачи

Будем предполагать, что минимизируемая функция  $f(x)$  удовлетворяет на отрезке  $X = [a, b]$  условию Липшица с известной константой  $L$ :

$$|f(x) - f(x')| \leq L|x - x'|, \quad x, x' \in X.$$

Очевидно, что функция  $f(x)$  непрерывна и поэтому достигает на  $X$  своего минимального значения.

Пусть  $f(x^*) = \min_{x \in X} f(x)$ .

Точка глобального минимума может быть не единственной.

Будем предполагать, что задано либо число  $N$  вычислений значений функции  $f(x)$ , либо точность  $\delta$  отыскания значения минимума.

Если метод даёт в качестве приближенного к минимальному значение  $f(x^0)$ , то его погрешностью будем считать величину  $f(x^0) - f(x^*)$  (расстояние от точки  $x^0$  до точек глобального минимума во внимание не принимается).

Пусть задано число вычислений  $N$ . Положим

$$x_1^0 = a + \frac{b-a}{2N}, \quad x_2^0 = a + 3\frac{b-a}{2N}, \quad \dots, \quad x_N^0 = a + (2N-1)\frac{b-a}{2N}.$$

Вычислим значения  $f(x_1^0), \dots, f(x_N^0)$  и в качестве приближения к минимальному примем значение  $\min_{i=1, \dots, N} f(x_i^0)$

Пусть  $x^*$  — точка глобального минимума. Тогда, найдётся точка  $x_j^0 (j \in \{1, \dots, N\})$  такая, что  $|x_j^0 - x^*| \leq \frac{b-a}{2N}$ . С учётом условия Липшица имеем

$$0 \leq \min_{i=1, \dots, N} f(x_i^0) - f(x^*) \leq f(x_j^0) - f(x^*) \leq L|x_j^0 - x^*| \leq L\frac{b-a}{2N}.$$

Поэтому погрешность метода не превосходит  $L\frac{b-a}{2N}$ .

Положим  $x_1 = a$ ,  $x_2 = b$ . Пусть вычисления проведены в точках  $x_1, \dots, x_i$ :  $y_1 = f(x_1), \dots, y_i = f(x_i)$ .

В силу условия Липшица

$$f(x) \geq y_j - L|x - x_j|, \quad x \in X, \quad j = 1, \dots, i,$$

и поэтому

$$f(x) \geq \varphi_i(x) \stackrel{\text{def}}{=} \max_{j=1, \dots, i} \{y_j - L|x - x_j|\}.$$

Функция  $\varphi_i$  является точной минорантой, принимающей в точках  $x_1, \dots, x_i$  значения соответственно  $y_1, \dots, y_i$ .

Точка  $x_{i+1}$  выбирается по правилу  $x_{i+1} = \arg \min_{x \in X} \varphi_i(x)$ .




График функции  $\varphi_i$

После  $N$  вычислений погрешность метода не превосходит величины

$$\min_{i=1,\dots,N} f(x_i) - \min_{x \in X} \varphi_N(x)$$



Если же требуется обеспечить отыскание значения минимума с точностью не хуже  $\delta$ , то следует прекратить вычисления, как только

$$\min_{i=1,\dots,N} f(x_i) - \min_{x \in X} \varphi_N(x) \leq \delta$$

# Пример двумерной функции

Функция Химмельблау

$$f(x, y) = (x^2 + y - 11)^2 + (x + y^2 - 7)^2$$





## Проблемы:

- нет универсальных алгоритмов поиска глобального минимума
- неясно, как выбрать начальное приближение (зависит от задачи и интуиции)

## Подходы:

- методы локальной оптимизации (результат зависит от выбора начального приближения)
- случайный поиск (без гарантии)
- методы глобальной оптимизации (для особых классов функций)

# МЕТОДЫ БЕЗУСЛОВНОЙ МИНИМИЗАЦИИ ГЛАДКИХ ФУНКЦИЙ

---

# Обобщённый алгоритм

Перейдём к минимизации многомерных дифференцируемых функций. Решается задача


$$\min_{x \in \mathbb{R}^n} f(x), \quad f(x) \in C^1$$

## Обобщённый алгоритм

1.  $k := 1$ , выбрать начальную точку  $x_1$ .
2. *Проверка условий останова.* Если условия выполнены, то поиск прекратить,  $x_k$  — решение, иначе перейти к п. 3.
3. *Расчёт направления поиска  $p_k$ .*
4. *Расчёт длины шага.* Определить  $\alpha_k$ , обеспечивающее, например,  $f(x_k + \alpha_k p_k) < f(x_k)$ .
5. *Пересчёт оценки решения.*  $x_{k+1} := x_k + \alpha_k p_k$ ,  $k := k + 1$ , перейти к п. 2.

# Геометрическое представление процесса поиска

Процесс функционирования алгоритмов поиска экстремума функции удобно иллюстрировать с помощью изображения траектории поиска экстремума в плоскости линий уровня функции двух переменных  $y = f(x_1, x_2)$ .



Типовая траектория поиска минимума функции

Предположим, что в любой точке  $x$  можно вычислить градиент функции  $\nabla f(x)$ .

Основная идея метода заключается в том, чтобы идти в направлении наискорейшего спуска, а это направление задаётся антиградиентом  $-\nabla f(x)$ .

В такой ситуации начиная с некоторого начального приближения  $x^0$ , строится итерационная последовательность

$$x^{k+1} = x^k - \gamma_k \nabla f(x^k)$$

где параметр  $\gamma_k \geq 0$  задаёт скорость градиентного спуска.

Этот метод, редко применяется на практике в «чистом виде», но служит моделью для построения более реалистических алгоритмов.

# Градиентный метод. Сходимость

Рассмотрим простейший вариант градиентного метода, в котором

$\gamma_k \equiv \gamma$ :

$$x^{k+1} = x^k - \gamma \nabla f(x^k) \quad (1)$$

## Теорема 1.

Пусть  $f(x)$  дифференцируема на  $\mathbb{R}^n$ , градиент  $f(x)$  удовлетворяет условию Липшица:  $\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|$

$f(x)$  ограничена снизу:  $f(x) \geq f^* > -\infty$

и  $\gamma$  удовлетворяет условию  $0 < \gamma < 2/L$

Тогда в методе (1) градиент стремится к нулю:

$$\lim_{k \rightarrow \infty} \nabla f(x^k) = 0,$$

а функция  $f(x)$  монотонно убывает:  $f(x^{k+1}) \leq f(x^k)$ .

# Метод градиентного спуска с постоянным шагом

Алгоритм.

1. Задать начальную точку  $x^0$ , погрешности расчёта  $\varepsilon_1 > 0$ ,  $\varepsilon_2 > 0$ ,  $M$  — предельное число итераций. Найти градиент функции в произвольной точке  $\nabla f(x) = \left( \frac{\partial f(x)}{\partial x_1}, \dots, \frac{\partial f(x)}{\partial x_n} \right)^T$ .
2. Принять  $k := 0$ .
3. Вычислить  $\nabla f(x^k)$ .
4. Проверить выполнение критерия окончания  $\|\nabla f(x^k)\| < \varepsilon_1$ :
  - если критерий выполнен, расчёт закончен  $x^* := x^k$ ;
  - если критерий не выполнен, то перейти к п. 5;
5. Проверить выполнение неравенства  $k \geq M$ :
  - если неравенство выполнено, то расчёт окончен:  $x^* := x^k$ ;
  - если нет, то перейти к п. 6.

# Метод градиентного спуска с постоянным шагом

Алгоритм.

6. Задать величину шага  $\gamma$ .

7. Вычислить  $x^{k+1} := x^k - \gamma \nabla f(x^k)$ .

8. Проверить выполнение условия  $f(x^{k+1}) - f(x^k) < 0$ :

- если условие выполнено, то перейти к п. 9;
- если условие не выполнено, принять  $\gamma := \frac{\gamma}{2}$  и перейти к п. 7.

9. Проверить выполнение условий  $\|x^{k+1} - x^k\| \leq \varepsilon_2$ ,  
 $|f(x^{k+1}) - f(x^k)| \leq \varepsilon_2$ :

- если оба условия выполнены при текущем значении  $k$  и при  $k - 1$ , то расчёт окончен и  $x^* := x^{k+1}$ ;
- если хотя бы одно из условий не выполнено, то принять  $k := k + 1$  и перейти к п. 3.



В случае, когда минимизируемая функция  $f$  не предполагается выпуклой, градиентный метод может обеспечить лишь сходимость к множеству стационарных точек функции  $f$ .

Градиентный метод (1) (или даже с произвольным выбором  $\gamma_k$ ), начатый из некоторой стационарной точки  $x^0$ , останется в этой точке:  $x^k = x^0$  для всех  $k$ . Иными словами, градиентный метод «застревает» в любой стационарной точке — точке максимума, минимума или седловой.

Градиентный метод «не отличает» точек локального минимума от глобального и никакой гарантии сходимости к глобальному минимуму он не даёт.

В условиях теоремы 1 скорость сходимости  $\nabla f(x^k)$  к 0 может быть очень медленной.

## Определение.

Функция  $f$ , определённая на выпуклом множестве  $X \in \mathbb{R}^n$ , называется строго выпуклой на  $X$ , если

$$f(\lambda x^1 + (1 - \lambda)x^2) < \lambda f(x^1) + (1 - \lambda)f(x^2)$$

при всех  $x^1, x^2 \in X$ ,  $\lambda \in [0, 1]$ .

## Определение.

Функция  $f$ , определённая на выпуклом множестве  $X \in \mathbb{R}^n$ , называется сильно выпуклой с константой  $l > 0$ , если

$$f(\lambda x^1 + (1 - \lambda)x^2) \leq \lambda f(x^1) + (1 - \lambda)f(x^2) - l\lambda(1 - \lambda) \frac{\|x^1 - x^2\|^2}{2}$$

при всех  $x^1, x^2 \in X$ ,  $\lambda \in [0, 1]$ .

Рассмотрим поведение градиентного метода для более узкого класса функций — сильно выпуклых. В этом случае градиентный метод сходится к точке минимума со скоростью геометрической прогрессии.

## Теорема 2.

Пусть  $f(x)$  дифференцируема на  $\mathbb{R}^n$ , её градиент удовлетворяет условию Липшица с константой  $L$  и  $f(x)$  является сильно выпуклой функцией с константой  $l$ . Тогда при  $0 < \gamma < 2/L$  градиентный метод сходится к единственной точке глобального минимума  $x^*$  со скоростью геометрической прогрессии:

$$\|x^k - x^*\| \leq cq^k, \quad 0 \leq q < 1$$

$$\text{или } \|x^{k+1} - x^*\| \leq q \|x^k - x^*\|$$

# Устойчивость решения

При практическом решении задач оптимизации постоянно приходится сталкиваться со следующей проблемой.

Пусть метод оптимизации приводит к построению минимизирующей последовательности, следует ли отсюда её сходимости к решению? То есть если  $f(x)$  близко к  $f(x^*)$ , можно ли судить о близости точки  $x$  к решению  $x^*$ ?

Такого типа проблемы относятся к области теории экстремальных задач, связанной с понятием устойчивости.

Для количественной оценки устойчивости используют следующий «нормированный» показатель.

## Определение.

Назовём *обусловленностью* точки минимума  $x^*$  число



$$\mu = \overline{\lim}_{\delta \rightarrow 0} \left( \sup_{x \in L_\delta} \|x - x^*\|^2 \middle/ \inf_{x \in L_\delta} \|x - x^*\|^2 \right),$$
$$L_\delta = \{x : f(x) = f(x^*) + \delta\}.$$

Иначе говоря,  $\mu$  характеризует степень вытянутости линий уровня  $f(x)$  в окрестности  $x^*$ . Ясно, что всегда  $\mu \geq 1$ . Если  $\mu$  велико, то линии уровня сильно вытянуты — функция имеет овражный характер, т. е. резко возрастает по одним направлениям и слабо меняется по другим. В таких случаях говорят о плохо обусловленных задачах минимизации.

Если же  $\mu$  близко к 1, то линии уровня  $f(x)$  близки к сферам; это соответствует хорошо обусловленным задачам. В дальнейшем мы увидим, что число обусловленности  $\mu$  возникает во многих проблемах, связанных с безусловной минимизацией, и может служить одним из показателей сложности задачи.

## Ещё один пример плохо обусловленной задачи

Задача линейной алгебры. Решение системы уравнений  $Ax = b$ .  
 $A$  — квадратная матрица,  $x$  и  $b$  — векторы.





Плохо обусловленная система геометрически соответствует почти

# Пример овражной функции

Функция Розенброка

$$f(x, y) = (1 - x)^2 + 100(y - x^2)^2$$




Это типичный пример овражной функции.

Градиентный метод «прыгает» с одного склона оврага на другой и обратно, иногда почти не двигаясь в нужном направлении, что существенно замедляет сходимость.


# Овражный метод

Метод градиентного спуска оказывается очень медленным при движении по оврагу, причём при увеличении числа переменных целевой функции такое поведение метода становится типичным. Для борьбы с этим явлением используется метод оврагов, суть которого очень проста. Сделав два шага градиентного спуска и, получив две точки, третий шаг следует сделать в направлении вектора, соединяющего эти точки вдоль дна оврага.





# Овражный метод



При изгибах оврага овражный шаг приводит на склон оврага, с которого осуществляется спуск в район дна оврага.

Отметим, что описанный метод не работает, если дно оврага имеет размерность выше двух.

# Овражный метод

Алгоритм.

1. Задать точки  $\bar{x}_0, \bar{x}_1$ .
2. Из точек  $\bar{x}_0, \bar{x}_1$  совершить один шаг методом наискорейшего спуска, получить точки  $x_0, x_1$ .
3. Положить  $k := 1$ .
4. Произвести овражный шаг, получить точку:

$$\bar{x}_{k+1} = x_k - \frac{x_k - x_{k-1}}{\|x_k - x_{k-1}\|} h \operatorname{sgn}(f(x_k) - f(x_{k-1})),$$


где  $h$  — овражный шаг.

5. Из точки  $\bar{x}_{k+1}$  совершить один шаг методом наискорейшего спуска, получить точку  $x_{k+1}$ .
6. Проверить условие останова. При выполнении поиск прекратить, запомнить наилучшую точку, иначе  $k := k + 1$ , и перейти к п. 4.

# Метод циклического покоординатного спуска

Этот метод также называют методом Гаусса-Зейделя по аналогии с методом Гаусса-Зейделя для решения системы линейных уравнений.

Улучшает градиентный метод за счёт того, что на очередной итерации спуск осуществляется постепенно вдоль каждой из координат, однако новые  $\gamma_k$  теперь необходимо вычислять  $n$  раз за один шаг.



# Метод циклического покоординатного спуска

Алгоритм.

1. Задать начальную точку  $x^0$ , погрешности расчёта  $\varepsilon_1 > 0$ ,  $\varepsilon_2 > 0$ ,  $M$  — предельное число циклов расчёта, кратное  $n$ . Найти градиент функции  $\nabla f(x)$  в произвольной точке.
2. Задать номер цикла  $j := 0$ .
3. Проверить условие  $j \geq M$ :
  - если  $j \geq M$ , то принять  $x^* := x^{jk}$  и расчёт окончен;
  - если  $j < M$ , то перейти к п. 4.
4. Задать  $k := 0$ .
5. Проверить условие  $k \leq n - 1$ :
  - если  $k \leq n - 1$ , то перейти к п. 6;
  - если  $k = n$ , то принять  $j := j + 1$  и перейти к п. 3.
6. Вычислить  $\nabla f(x^{jk})$ .

# Метод циклического покоординатного спуска

7. Проверить выполнение критерия окончания  $\|\nabla f(x^{jk})\| < \varepsilon_1$ :

- если критерий выполнен, расчёт закончен  $x^* := x^{jk}$ ;
- если критерий не выполнен, то перейти к п. 8;

8. Найти  $t_k^*$  из условия:

$$t_k^* = \arg \min_{t_k \geq 0} f(x^{jk} - t_k \nabla f(x^{jk})_{k+1} e_{k+1})$$

9. Вычислить точку  $x^{jk+1} := x^{jk} - t_k^* \nabla f(x^{jk})_{k+1} e_{k+1}$ .

10. Проверить выполнение условий

$$\|x^{jk+1} - x^{jk}\| \leq \varepsilon_2, \quad |f(x^{jk+1}) - f(x^{jk})| \leq \varepsilon_2$$

- если оба условия выполнены при текущем значении цикла  $j$  и при  $j - 1$ , то расчёт окончен и  $x^* := x^{jk+1}$ ;
- если хотя бы одно из условий не выполнено, то принять  $k := k + 1$  и перейти к п. 5.

Рассмотрим общий градиентный метод

$$x^{k+1} = x^k - \gamma_k \nabla f(x^k)$$

при различных способах выбора длины шага  $\gamma_k$ .

На первый взгляд, кажется, что можно значительно повысить эффективность градиентного метода, если идти до минимума по направлению антиградиента:

$$\gamma_k = \arg \min_{\gamma \geq 0} \varphi_k(\gamma), \quad \varphi_k(\gamma) = f(x^k - \gamma \nabla f(x^k)).$$

При этом мы получаем так называемый метод наискорейшего спуска.

Алгоритм.

1. Задать начальную точку  $x^0$ , погрешности расчёта  $\varepsilon_1 > 0$ ,  $\varepsilon_2 > 0$ ,  $M$  — предельное число итераций. Найти градиент функции в произвольной точке  $\nabla f(x) = \left( \frac{\partial f(x)}{\partial x_1}, \dots, \frac{\partial f(x)}{\partial x_n} \right)^T$ .
2. Принять  $k := 0$ .
3. Вычислить  $\nabla f(x^k)$ .
4. Проверить выполнение критерия окончания  $\|\nabla f(x^k)\| < \varepsilon_1$ :
  - если критерий выполнен, расчёт закончен  $x^* := x^k$ ;
  - если критерий не выполнен, то перейти к п. 5;
5. Проверить выполнение неравенства  $k \geq M$ :
  - если неравенство выполнено, то расчёт окончен:  $x^* := x^k$ ;
  - если нет, то перейти к п. 6.

Алгоритм.

6. Задать величину шага  $\gamma^*$  из условия:

$$\gamma^* := \arg \min_{\gamma \geq 0} f(x^k - \gamma \nabla f(x^k))$$

7. Вычислить  $x^{k+1} := x^k - \gamma^* \nabla f(x^k)$ .

8. Проверить выполнение условий  $\|x^{k+1} - x^k\| \leq \varepsilon_2$ ,  
 $|f(x^{k+1}) - f(x^k)| \leq \varepsilon_2$ :

- если оба условия выполнены при текущем значении  $k$  и при  $k - 1$ , то расчёт окончен и  $x^* := x^{k+1}$ ;
- если хотя бы одно из условий не выполнено, то принять  $k := k + 1$  и перейти к п. 3.



Вопросы?